



ME613 - Análise de Regressão

Parte 11

Samara F. Kiihl - IMECC - UNICAMP

file:///Users/amac/Documents/GitHub/ME613-UNICAMP/ME613-UNICAMP.github.io/nulas/slides/parte11/parte11.html#1

1/62

Introdução

Fases na construção de um modelo:

- Coleta e preparação dos dados.
- Redução do número de variáveis preditoras.
- Refinamento e seleção de modelo.
- Validação do modelo.

Critérios para Seleção de Modelos

file:///Users/amac/Documents/GitHub/ME613-UNICAMP/ME613-UNICAMP.github.io/nulas/slides/parte11/parte11.html#1

2/62

Introdução

Se tivermos $p - 1$ variáveis preditoras, podemos construir 2^{p-1} modelos diferentes.

Mesmo se considerarmos todos esses modelos (computacionalmente intenso), precisaríamos de algum critério para selecionar entre eles.

Métodos para seleção de modelos/variáveis foram desenvolvidos para identificar um subgrupo de variáveis que são "boas" para o modelo, segundo algum critério.

Há vários critérios desenvolvidos na literatura. Neste curso, focaremos em seis.

R_p^2

Para o critério R_p^2 , a idéia é utilizar o coeficiente de determinação, R^2 para identificar subgrupos das variáveis preditoras que, quando incluídas no modelo, produzem um alto valor para R^2 .

R_p^2 indica que temos p parâmetros no modelo, isto é, $p - 1$ variáveis preditoras incluídas no modelo.

$$R_p^2 = 1 - \frac{SQE_p}{SQT}$$

O objetivo deste critério não é maximização: R_p^2 sempre irá aumentar conforme mais variáveis preditoras são incluídas no modelo. A idéia é comparar os diversos R_p^2 's e verificar se adicionar mais variáveis ainda traz um aumento.

Exemplo: Cirurgias


- Y : tempo de sobrevivência
- X_1 : blood clotting score
- X_2 : índice de prognóstico
- X_3 : teste de função enzimática
- X_4 : teste de função do fígado
- X_5 : idade (anos)
- X_6 : gênero (0=masculino, 1=feminino)
- X_7 : uso de álcool (1 = moderado, 0 = nenhum ou severo)
- X_8 : uso de álcool (1 = severo, 0 = nenhum ou moderado)

Exemplo

Considerando X_1, X_2, X_3 e X_4 , temos $2^4 = 16$ modelos possíveis.

Variáveis no modelo	p	R_p^2	Variáveis no modelo	p	R_p^2
nenhuma	1	0	X_2, X_3	3	0.663
X_1	2	0.061	X_2, X_4	3	0.483
X_2	2	0.221	X_3, X_4	3	0.599
X_3	2	0.428	X_1, X_2, X_3	4	0.757
X_4	2	0.422	X_1, X_2, X_4	4	0.487
X_1, X_2	3	0.263	X_1, X_3, X_4	4	0.612
X_1, X_3	3	0.549	X_2, X_3, X_4	4	0.718
X_1, X_4	3	0.43	X_1, X_2, X_3, X_4	5	0.759

Exemplo




$R^2_{a,p}$

Como R^2_p não leva em conta o número de parâmetros no modelo e sempre aumenta conforme temos mais variáveis incluídas, uma alternativa é usar:

$$R^2_{a,p} = 1 - \left(\frac{n-1}{n-p}\right) \frac{SQE_p}{SQT} = 1 - \frac{QME_p}{SQT/(n-1)}$$

$R^2_{a,p}$ aumenta se e somente se QME_p diminui.

Exemplo



Exemplo

Variáveis no modelo	p	R ² _{a,p}	Variáveis no modelo	p	R ² _{a,p}
nenhuma	1	0	X ₂ X ₃	3	0.65
X ₁	2	0.043	X ₂ X ₄	3	0.463
X ₂	2	0.206	X ₃ X ₄	3	0.584
X ₃	2	0.417	X ₁ X ₂ X ₃	4	0.743
X ₄	2	0.41	X ₁ X ₂ X ₄	4	0.456
X ₁ X ₂	3	0.234	X ₁ X ₃ X ₄	4	0.589
X ₁ X ₃	3	0.531	X ₂ X ₃ X ₄	4	0.701
X ₁ X ₄	3	0.408	X ₁ X ₂ X ₃ X ₄	5	0.74

C_p de Mallow

Este critério avalia o erro quadrático médio dos n valores ajustados segundo um modelo a ser considerado.

Erro de cada valor ajustado é dado por:

$$\hat{Y}_i - \mu_i$$

em que μ_i é o valor verdadeiro da função resposta.

Temos o viés:

$$E(\hat{Y}_i) - \mu_i$$

E um componente aleatório de erro:

$$\hat{Y}_i - E(\hat{Y}_i)$$

C_p de Mallow

$$(\hat{Y}_i - \mu_i)^2 = [(E(\hat{Y}_i) - \mu_i) + (\hat{Y}_i - E(\hat{Y}_i))]^2$$

$$E(\hat{Y}_i - \mu_i)^2 = [E(\hat{Y}_i) - \mu_i]^2 + \text{Var}(\hat{Y}_i)$$

Erro quadrático médio total:

$$\sum_{i=1}^n [E(\hat{Y}_i) - \mu_i]^2 + \sum_{i=1}^n \text{Var}(\hat{Y}_i)$$

Medida para o critério:

$$\Gamma_p = \frac{1}{\sigma^2} \left[\sum_{i=1}^n [E(\hat{Y}_i) - \mu_i]^2 + \sum_{i=1}^n \text{Var}(\hat{Y}_i) \right]$$

(erro quadrático médio total dividido pela verdadeira variância do erro)

13/62

file:///Users/ismac/Documents/GitHub/ME613-UNICAMP/ME613-UNICAMPgithub.io/nulus/slides/parte11/parte11.html#1

13/62

C_p de Mallow

Se o modelo com $p - 1$ variáveis é adequado, então $E \left[\frac{SQE_p}{(n-p)} \right] = \sigma^2$, de maneira que $E \left[\frac{SQE_p}{QME(X_1, \dots, X_{p-1})} \right] = n - p$.

Portanto, se o modelo com $p - 1$ variáveis é aproximadamente adequado, esperamos que $C_p \approx p$.

Procuramos o menor C_p tal que $C_p \approx p$.

15/62

file:///Users/ismac/Documents/GitHub/ME613-UNICAMP/ME613-UNICAMPgithub.io/nulus/slides/parte11/parte11.html#1

15/62

C_p de Mallow

Estamos considerando incluir $p - 1$ variáveis, mas assuma que o número ideal de variáveis a serem incluídas no modelo seja $P - 1 > p - 1$.

Se assumirmos que o modelo incluindo as $P - 1$ variáveis é correto, temos que $QME(X_1, \dots, X_{P-1})$ é um estimador não viesado para σ^2 .

Estimador para Γ_p é dado por:

$$C_p = \frac{SQE_p}{QME(X_1, \dots, X_{P-1})} - (n - 2p)$$

14/62

file:///Users/ismac/Documents/GitHub/ME613-UNICAMP/ME613-UNICAMPgithub.io/nulus/slides/parte11/parte11.html#1

14/62

Exemplo

Modelo considerando as variáveis X_1, X_2, X_3 e X_4 ($P - 1 = 4$)

Incluindo apenas X_4 ($p = 2$):

$$C_p = \frac{SQE(X_4)}{QME(X_1, \dots, X_4)} - (n - 2p)$$

16/62

file:///Users/ismac/Documents/GitHub/ME613-UNICAMP/ME613-UNICAMPgithub.io/nulus/slides/parte11/parte11.html#1

16/62

Exemplo


```
## Analysis of Variance Table
##
## Response: lnY
##           Df Sum Sq Mean Sq F value    Pr(>F)
## X4          1  5.3990    5.3990   37.894 1.092e-07 ***
## Residuals  52  7.4087    0.1425
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

## Analysis of Variance Table
##
## Response: lnY
##           Df Sum Sq Mean Sq F value    Pr(>F)
## X1          1  0.7763    0.7763   12.3337 0.0009661 ***
## X2          1  2.5888    2.5888   41.1325 5.377e-08 ***
## X3          1  6.3341    6.3341  100.6408 1.810e-13 ***
## X4          1  0.0246    0.0246    0.3905 0.5349320
## Residuals  49  3.0840    0.0629
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

$$C_p = \frac{SQE(X_4)}{QME(X_1, \dots, X_4)} - (n - 2p) = \frac{7.4087314}{0.062938} - (54 - 2 \times 2) = 67.7147725$$

Exemplo

```
library(leaps)
leaps<-regsubsets(lnY~X1+X2+X3+X4,data=dados,nbest=10)
plot(leaps,scale="Cp")
```



AIC e BIC

Procuramos modelos com valores pequenos de *AIC*, *BIC*.

AIC:


$$AIC_p = n \ln(SQE_p) - n \ln n + 2p$$

BIC:

$$BIC_p = n \ln(SQE_p) - n \ln n + \ln(n)p$$

Exemplo

```
plot(leaps,scale="bic")
```



PRESS_p

PRESS_p (): critério para medir quão adequado é o uso dos valores ajustados obtidos a partir de um modelo com menos variáveis para prever os valores observados de *Y*.

SQE = $\sum(Y_i - \hat{Y}_i)^2$ também serve para este propósito.

A diferença é que a medida *PRESS* é obtida após a exclusão da *i*-ésima observação e estimação do modelo com as *n* – 1 observações restantes, e então usar este modelo para prever o valor de *Y* para a *i*-ésima observação.

Notação: $\hat{Y}_{i(i)}$ indica o valor predito para a *i*-ésima observação quando esta foi excluída na obtenção do modelo.

Exemplo

```
library(qpcR)
modelo1 <- lm(lnY ~ 1,data=dados)
modelo2 <- lm(lnY ~ X1,data=dados)
modelo3 <- lm(lnY ~ X2,data=dados)
modelo4 <- lm(lnY ~ X3,data=dados)
modelo5 <- lm(lnY ~ X4,data=dados)
modelo6 <- lm(lnY ~ X1+X2,data=dados)
modelo7 <- lm(lnY ~ X1+X3,data=dados)
modelo8 <- lm(lnY ~ X1+X4,data=dados)
modelo9 <- lm(lnY ~ X2+X3,data=dados)
modelo10 <- lm(lnY ~ X2+X4,data=dados)
modelo11 <- lm(lnY ~ X3+X4,data=dados)
modelo12 <- lm(lnY ~ X1+X2+X3,data=dados)
modelo13 <- lm(lnY ~ X1+X2+X4,data=dados)
modelo14 <- lm(lnY ~ X1+X3+X4,data=dados)
modelo15 <- lm(lnY ~ X2+X3+X4,data=dados)
modelo16 <- lm(lnY ~ X1+X2+X3+X4,data=dados)
PRESS(modelo1,verbose=FALSE)$stat

## [1] 13.2956
```

PRESS_p

$$PRESS_p = \sum_{i=1}^n (Y_i - \hat{Y}_{i(i)})^2$$

Modelos com *PRESS_p* pequenos são considerados bons candidatos (com erro de predição pequeno).

Não é preciso ajustar *n* – 1 vezes o modelo para calcular o *PRESS_p*.

Seja *d_i* = *Y_i* – $\hat{Y}_{i(i)}$, reescrevemos: $d_i = \frac{e_i}{1-h_{ii}}$

em que *e_i* é o resíduo para a *i*-ésima observação e *h_{ii}* é o *i*-ésimo elemento da diagonal de **H** = **X^T(X^TX)⁻¹X**, obtidos a partir do modelo de regressão com todas as observações incluídas.

Exemplo

Variáveis no modelo	p	<i>PRESS_p</i>	Variáveis no modelo	p	<i>PRESS_p</i>
nenhuma	1	13.296	X ₂ X ₃	3	5.065
X ₁	2	13.512	X ₂ X ₄	3	7.476
X ₂	2	10.744	X ₃ X ₄	3	6.121
X ₃	2	8.327	X ₁ X ₂ X ₃	4	3.914
X ₄	2	8.025	X ₁ X ₂ X ₄	4	7.903
X ₁ X ₂	3	11.062	X ₁ X ₃ X ₄	4	6.207
X ₁ X ₃	3	6.988	X ₂ X ₃ X ₄	4	4.597
X ₁ X ₄	3	8.472	X ₁ X ₂ X ₃ X ₄	5	4.069

Procedimentos Automáticos para Seleção de Modelos

"Best" Subsets Algorithms

Para o exemplo visto anteriormente, se considerarmos todas as variáveis, temos $2^8 = 256$ modelos possíveis.

Exemplo - Usando AIC_p

```
library(bestglm)
Xy = dados[,~9] # excluindo coluna do Y original, usamos ln(Y) como variável resposta
names(Xy) <- c(names(Xy)[1:8], "y")
modelos <- bestglm(Xy, IC="AIC", TopModels = 2)
modelos$Subsets

##      (Intercept)  X1    X2    X3    X4    X5    X6    X7    X8
## 0              TRUE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## 1              TRUE FALSE FALSE  TRUE FALSE FALSE FALSE FALSE FALSE
## 2              TRUE FALSE  TRUE  TRUE FALSE FALSE FALSE FALSE FALSE
## 3              TRUE FALSE  TRUE  TRUE FALSE FALSE FALSE FALSE  TRUE
## 4              TRUE  TRUE  TRUE  TRUE FALSE FALSE FALSE FALSE  TRUE
## 5              TRUE  TRUE  TRUE  TRUE FALSE FALSE  TRUE FALSE  TRUE
## 6*             TRUE  TRUE  TRUE  TRUE FALSE  TRUE  TRUE FALSE  TRUE
## 7              TRUE  TRUE  TRUE  TRUE FALSE  TRUE  TRUE  TRUE  TRUE
## 8              TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
##      logLikelihood      AIC
## 0      38.85126    -77.70252
## 1      53.91343    -105.82686
## 2      68.24165    -132.48329
## 3      79.49246    -152.98493
## 4      86.67568    -165.35135
## 5      87.90259    -165.80517
## 6*      88.91714    -165.83429
## 7      89.36782    -164.73565
## 8      89.38549    -162.77098
```

Exemplo - Usando AIC_p

```
melhor <- which(modelos$Subsets$AIC==min(modelos$Subsets$AIC))
numvar <- dim(Xy)[2]-1 # total de variáveis consideradas inicialmente
varincludas <- modelos$Subsets[melhor,2:(numvar+1)] # variaveis escolhidas segundo criterio
varincludas

##      X1    X2    X3    X4    X5    X6    X7    X8
## 6*  TRUE  TRUE  TRUE  FALSE  TRUE  TRUE  FALSE  TRUE

modeloescolhidoAIC <- lm(y ~ ., data=Xy[,c(which(varincludas==TRUE), which(names(Xy)=="y"))])
summary(modeloescolhidoAIC)$coef

##              Estimate Std. Error  t value    Pr(>|t|)
## (Intercept)  4.053974209  0.234793506  17.266126  5.572016e-22
## X1           0.071517057  0.018637294   3.837309  3.701898e-04
## X2           0.013755482  0.001709437   8.046792  2.169036e-10
## X3           0.015116499  0.001385313  10.911972  1.777375e-14
## X5          -0.003450094  0.002571776  -1.341522  1.861972e-01
## X6           0.087316639  0.057701672   1.513243  1.369140e-01
## X8           0.350903932  0.076391406   4.593500  3.276184e-05
```

Exemplo - Usando BIC_p

```
modelos <- bestglm(Xy,IC="BIC")
modelos$Subsets

##      (Intercept)  X1  X2  X3  X4  X5  X6  X7  X8
## 0      TRUE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## 1      TRUE FALSE FALSE TRUE FALSE FALSE FALSE FALSE
## 2      TRUE FALSE TRUE TRUE FALSE FALSE FALSE FALSE
## 3      TRUE FALSE TRUE TRUE FALSE FALSE FALSE FALSE
## 4*     TRUE TRUE TRUE TRUE FALSE FALSE FALSE FALSE
## 5      TRUE TRUE TRUE TRUE FALSE FALSE TRUE FALSE
## 6      TRUE TRUE TRUE TRUE FALSE TRUE TRUE FALSE
## 7      TRUE TRUE TRUE TRUE FALSE TRUE TRUE TRUE
## 8      TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
##      logLikelihood      BIC
## 0      38.85126      -77.70252
## 1      53.91343      -103.83788
## 2      68.24165      -128.50532
## 3      79.49246      -147.01798
## 4*     86.67568      -157.39542
## 5      87.90259      -155.86025
## 6      88.91714      -153.90039
## 7      89.36782      -150.81276
## 8      89.38549      -146.85911
```

Exemplo - Usando $PRESS_p$

```
modelos <- bestglm(Xy,IC="LOOCV")
modelos$Subsets

##      (Intercept)  X1  X2  X3  X4  X5  X6  X7  X8
## 0      TRUE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## 1      TRUE FALSE FALSE TRUE FALSE FALSE FALSE FALSE
## 2      TRUE FALSE TRUE TRUE FALSE FALSE FALSE FALSE
## 3      TRUE FALSE TRUE TRUE FALSE FALSE FALSE FALSE
## 4*     TRUE TRUE TRUE TRUE FALSE FALSE FALSE FALSE
## 5      TRUE TRUE TRUE TRUE FALSE FALSE TRUE FALSE
## 6      TRUE TRUE TRUE TRUE FALSE TRUE TRUE FALSE
## 7      TRUE TRUE TRUE TRUE FALSE TRUE TRUE TRUE
## 8      TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
##      logLikelihood      LOOCV
## 0      38.85126      0.24621473
## 1      53.91343      0.15419845
## 2      68.24165      0.09380257
## 3      79.49246      0.06424821
## 4*     86.67568      0.05069947
## 5      87.90259      0.05153172
## 6      88.91714      0.05133936
## 7      89.36782      0.05201306
## 8      89.38549      0.05428207
```

Exemplo - Usando BIC_p

```
melhor <- which(modelos$Subsets$BIC==min(modelos$Subsets$BIC))
varincludas <- modelos$Subsets[melhor,2:(numvar+1)] # variaveis escolhidas segundo criterio
varincludas
```

```
##      X1  X2  X3  X4  X5  X6  X7  X8
## 4* TRUE TRUE TRUE FALSE FALSE FALSE TRUE
```

```
modeloescolhidoBIC <- lm(y ~ .,data=Xy[,c(which(varincludas==TRUE),which(names(Xy)=="y"))])
summary(modeloescolhidoBIC)$coef
```

```
##      Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.85241856 0.192695224 19.992289 3.279284e-25
## X1          0.07332263 0.018973044  3.864569 3.273887e-04
## X2          0.01418507 0.001730632  8.196469 9.581863e-11
## X3          0.01545270 0.001395609 11.072371 6.145977e-15
## X8          0.35296762 0.077190626  4.572675 3.290701e-05
```

Exemplo - Usando $PRESS_p$

```
melhor <- which(modelos$Subsets$LOOCV==min(modelos$Subsets$LOOCV))
varincludas <- modelos$Subsets[melhor,2:(numvar+1)] # variaveis escolhidas segundo criterio
varincludas
```

```
##      X1  X2  X3  X4  X5  X6  X7  X8
## 4* TRUE TRUE TRUE FALSE FALSE FALSE TRUE
```

```
modeloescolhidoPRESS <- lm(y ~ .,data=Xy[,c(which(varincludas==TRUE),which(names(Xy)=="y"))])
summary(modeloescolhidoPRESS)$coef
```

```
##      Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.85241856 0.192695224 19.992289 3.279284e-25
## X1          0.07332263 0.018973044  3.864569 3.273887e-04
## X2          0.01418507 0.001730632  8.196469 9.581863e-11
## X3          0.01545270 0.001395609 11.072371 6.145977e-15
## X8          0.35296762 0.077190626  4.572675 3.290701e-05
```


Exemplo - C_p de Mallow, R_p^2 , $R_{a,p}^2$ e BIC_p

```
library(leaps)
modelos <- regsubsets(y ~ ., data=Xy, nbest=2)
resultados = data.frame(cbind("p"=rowSums(summary(modelos)$which), summary(modelos)$which,
                              "Cp"=round(summary(modelos)$cp, 2),
                              "R2"=round(summary(modelos)$rsq, 2),
                              "R2adj"=round(summary(modelos)$adjr2, 2), "BIC"=round(summary(modelos)$bic, 2)))
resultados
```

##	p	X.Intercept.	X1	X2	X3	X4	X5	X6	X7	X8	Cp	R2	R2adj	BIC
## 1	2		1	0	0	1	0	0	0	0	117.41	0.43	0.42	-22.15
## 2	2		1	0	0	0	1	0	0	0	119.17	0.42	0.41	-21.58
## 3	3		1	0	1	1	0	0	0	0	50.47	0.66	0.65	-46.81
## 4	3		1	0	0	1	1	0	0	0	69.13	0.60	0.58	-37.44
## 5	4		1	0	1	1	0	0	0	1	18.91	0.78	0.76	-65.33
## 6	4		1	1	1	1	0	0	0	0	24.98	0.76	0.74	-60.50
## 7	5		1	1	1	1	0	0	0	1	5.75	0.83	0.82	-75.70
## 8	5		1	0	1	1	1	0	0	1	10.27	0.81	0.80	-71.01
## 9	6		1	1	1	1	0	0	1	1	5.54	0.84	0.82	-74.17
## 10	6		1	1	1	1	0	1	0	1	6.02	0.84	0.82	-73.63
## 11	7		1	1	1	1	0	1	1	1	5.79	0.84	0.82	-72.21
## 12	7		1	1	1	1	0	0	1	1	7.03	0.84	0.82	-70.76
## 13	8		1	1	1	1	0	1	1	1	7.03	0.85	0.82	-69.12
## 14	8		1	1	1	1	1	1	0	1	7.74	0.84	0.82	-68.28
## 15	9		1	1	1	1	1	1	1	1	9.00	0.85	0.82	-65.17

33/62

file:///Users/amac/Documents/GitHub/ME613-UNICAMP/ME613-UNICAMPgithub.io/nulas/slides/part11/part11.html#1

33/62

file:///Users/amac/Documents/GitHub/ME613-UNICAMP/ME613-UNICAMPgithub.io/nulas/slides/part11/part11.html#1

34/62

Início considerando $P - 1$ variáveis.

1- Ajuste uma regressão linear simples com cada uma das $P - 1$ variáveis. Para cada regressão, calcule a estatística t^* para testar se o coeficiente angular é 0.

$$t_k^* = \frac{\hat{\beta}_k}{\sqrt{\widehat{Var}(\hat{\beta}_k)}}$$

2- Considere a variável cujo $|t^*|$ é o maior. Inclua esta variável caso $|t^*|$ esteja acima de algum valor pré-determinado.

3 - Se alguma variável é incluída, por exemplo, X_7 ajustam-se regressões com pares de variáveis, sendo que sempre uma delas é X_7 . Calcula-se t^* para a nova variável incluída e repita o passo 2 para decidir qual a segunda variável a ser incluída no modelo.

4 Repita até considerar todas as variáveis.

35/62

file:///Users/amac/Documents/GitHub/ME613-UNICAMP/ME613-UNICAMPgithub.io/nulas/slides/part11/part11.html#1

35/62

file:///Users/amac/Documents/GitHub/ME613-UNICAMP/ME613-UNICAMPgithub.io/nulas/slides/part11/part11.html#1

36/62

Método

- Método menos intensivo computacionalmente.
- Ao final, obtém-se apenas 1 modelo candidato.

• , ,

1. Ajuste uma regressão linear múltipla com todas as $P - 1$ variáveis.
2. Teste iterativamente se uma das variáveis pode ser eliminada.

Exemplo:

```
completo = lm(y~.,data=Xy)
vazio = lm(y~1, data=Xy)
step(vazio, scope=list(upper=completo, lower=vazio), direction='forward', trace=TRUE)
Start:  AIC=-75.7
y ~ 1
```

	Df	Sum of Sq	RSS	AIC
+ X3	1	5.4762	7.3316	-103.827
+ X4	1	5.3990	7.4087	-103.262
+ X2	1	2.8285	9.9792	-87.178
+ X8	1	1.7798	11.0279	-81.782
+ X1	1	0.7763	12.0315	-77.079
+ X6	1	0.6897	12.1180	-76.692
<none>			12.8077	-75.703
+ X5	1	0.2691	12.5386	-74.849
+ X7	1	0.2052	12.6025	-74.575

Exemplo:

```
Step:  AIC=-130.48
y ~ X3 + X2
```

	Df	Sum of Sq	RSS	AIC
+ X8	1	1.46961	2.8429	-150.99
+ X1	1	1.20395	3.1085	-146.16
+ X4	1	0.69836	3.6141	-138.02
+ X7	1	0.22632	4.0862	-131.39
+ X5	1	0.16461	4.1479	-130.59
<none>			4.3125	-130.48
+ X6	1	0.08245	4.2300	-129.53

Exemplo:

```
Step:  AIC=-103.83
y ~ X3
```

	Df	Sum of Sq	RSS	AIC
+ X2	1	3.01908	4.3125	-130.48
+ X4	1	2.20187	5.1297	-121.11
+ X1	1	1.55061	5.7810	-114.66
+ X8	1	1.13756	6.1940	-110.93
<none>			7.3316	-103.83
+ X6	1	0.25854	7.0730	-103.77
+ X5	1	0.23877	7.0928	-103.61
+ X7	1	0.06498	7.2666	-102.31

Exemplo:

```
Step:  AIC=-150.98
y ~ X3 + X2 + X8
```

	Df	Sum of Sq	RSS	AIC
+ X1	1	0.66408	2.1788	-163.35
+ X4	1	0.46630	2.3766	-158.66
+ X6	1	0.13741	2.7055	-151.66
<none>			2.8429	-150.99
+ X5	1	0.07081	2.7721	-150.35
+ X7	1	0.02464	2.8182	-149.46

Exemplo:

Step: AIC=-163.35
y ~ X3 + X2 + X8 + X1

	Df	Sum of Sq	RSS	AIC
+ X6	1	0.096791	2.0820	-163.81
<none>			2.1788	-163.35
+ X5	1	0.075876	2.1029	-163.26
+ X4	1	0.041701	2.1371	-162.40
+ X7	1	0.022944	2.1559	-161.92

Exemplo:

Step: AIC=-163.83
y ~ X3 + X2 + X8 + X1 + X6 + X5

	Df	Sum of Sq	RSS	AIC
<none>			2.0052	-163.83
+ X7	1	0.033193	1.9720	-162.74
+ X4	1	0.002284	2.0029	-161.90

Call:
lm(formula = y ~ X3 + X2 + X8 + X1 + X6 + X5, data = Xy)

Coefficients:

(Intercept)	X3	X2	X8	X1	X6	X5
4.05397	0.01512	0.01376	0.35090	0.07152	0.08732	-0.00345

Exemplo:

Step: AIC=-163.81
y ~ X3 + X2 + X8 + X1 + X6

	Df	Sum of Sq	RSS	AIC
+ X5	1	0.076782	2.0052	-163.83
<none>			2.0820	-163.81
+ X7	1	0.022387	2.0596	-162.39
+ X4	1	0.016399	2.0656	-162.23

Exemplo:

```
completo = lm(y~.,data=Xy)
vazio = lm(y~1, data=Xy)
step(completo, scope=list(upper=completo, lower=vazio), direction='backward', trace=TRUE)
```

Start: AIC=-160.77
y ~ X1 + X2 + X3 + X4 + X5 + X6 + X7 + X8

	Df	Sum of Sq	RSS	AIC
- X4	1	0.00129	1.9720	-162.74
- X7	1	0.03220	2.0029	-161.90
- X5	1	0.07354	2.0443	-160.79
<none>			1.9707	-160.77
- X6	1	0.08415	2.0549	-160.51
- X1	1	0.31809	2.2888	-154.69
- X8	1	0.84573	2.8165	-143.49
- X2	1	2.09045	4.0612	-123.72
- X3	1	2.99085	4.9616	-112.91

Exemplo:

Step: AIC=-162.74
y ~ X1 + X2 + X3 + X5 + X6 + X7 + X8

	Df	Sum of Sq	RSS	AIC
- X7	1	0.0332	2.0052	-163.834
<none>		1.9720	-162.736	
- X5	1	0.0876	2.0596	-162.389
- X6	1	0.0971	2.0691	-162.141
- X1	1	0.6267	2.5988	-149.833
- X8	1	0.8446	2.8166	-145.486
- X2	1	2.6731	4.6451	-118.471
- X3	1	5.0986	7.0706	-95.784

Exemplo:

Call:
lm(formula = y ~ X1 + X2 + X3 + X5 + X6 + X8, data = Xy)

Coefficients:

(Intercept)	X1	X2	X3	X5	X6	X8
4.05397	0.07152	0.01376	0.01512	-0.00345	0.08732	0.35090

Exemplo:

Step: AIC=-163.83
y ~ X1 + X2 + X3 + X5 + X6 + X8

	Df	Sum of Sq	RSS	AIC
<none>			2.0052	-163.834
- X5	1	0.0768	2.0820	-163.805
- X6	1	0.0977	2.1029	-163.265
- X1	1	0.6282	2.6335	-151.117
- X8	1	0.9002	2.9055	-145.809
- X2	1	2.7626	4.7678	-119.064
- X3	1	5.0801	7.0853	-97.672

Exemplo:

completo = lm(y~.,data=Xy)
vazio = lm(y~1, data=Xy)
step(vazio, scope=list(upper=completo, lower=vazio), direction='both', trace=TRUE)

Start: AIC=-75.7
y ~ 1

	Df	Sum of Sq	RSS	AIC
+ X3	1	5.4762	7.3316	-103.827
+ X4	1	5.3990	7.4087	-103.262
+ X2	1	2.8285	9.9792	-87.178
+ X8	1	1.7798	11.0279	-81.782
+ X1	1	0.7763	12.0315	-77.079
+ X6	1	0.6897	12.1180	-76.692
<none>			12.8077	-75.703
+ X5	1	0.2691	12.5386	-74.849
+ X7	1	0.2052	12.6025	-74.575

Exemplo:

Step: AIC=-103.83
y ~ X3

	Df	Sum of Sq	RSS	AIC
+ X2	1	3.0191	4.3125	-130.483
+ X4	1	2.2019	5.1297	-121.113
+ X1	1	1.5506	5.7810	-114.658
+ X8	1	1.1376	6.1940	-110.932
<none>			7.3316	-103.827
+ X6	1	0.2585	7.0730	-103.765
+ X5	1	0.2388	7.0928	-103.615
+ X7	1	0.0650	7.2666	-102.308
- X3	1	5.4762	12.8077	-75.703

Exemplo:

Step: AIC=-150.98
y ~ X3 + X2 + X8

	Df	Sum of Sq	RSS	AIC
+ X1	1	0.6641	2.1788	-163.351
+ X4	1	0.4663	2.3766	-158.659
+ X6	1	0.1374	2.7055	-151.660
<none>			2.8429	-150.985
+ X5	1	0.0708	2.7721	-150.347
+ X7	1	0.0246	2.8182	-149.455
- X8	1	1.4696	4.3125	-130.483
- X2	1	3.3511	6.1940	-110.932
- X3	1	4.9456	7.7885	-98.562

Exemplo:

Step: AIC=-130.48
y ~ X3 + X2

	Df	Sum of Sq	RSS	AIC
+ X8	1	1.4696	2.8429	-150.985
+ X1	1	1.2040	3.1085	-146.161
+ X4	1	0.6984	3.6141	-138.023
+ X7	1	0.2263	4.0862	-131.394
+ X5	1	0.1646	4.1479	-130.585
<none>			4.3125	-130.483
+ X6	1	0.0824	4.2300	-129.526
- X2	1	3.0191	7.3316	-103.827
- X3	1	5.6667	9.9792	-87.178

Exemplo:

Step: AIC=-163.35
y ~ X3 + X2 + X8 + X1

	Df	Sum of Sq	RSS	AIC
+ X6	1	0.0968	2.0820	-163.805
<none>			2.1788	-163.351
+ X5	1	0.0759	2.1029	-163.265
+ X4	1	0.0417	2.1371	-162.395
+ X7	1	0.0229	2.1559	-161.923
- X1	1	0.6641	2.8429	-150.985
- X8	1	0.9297	3.1085	-146.161
- X2	1	2.9873	5.1661	-118.731
- X3	1	5.4513	7.6301	-97.671

Exemplo:

Step: AIC=-163.81
y ~ X3 + X2 + X8 + X1 + X6

	Df	Sum of Sq	RSS	AIC
+ X5	1	0.0768	2.0052	-163.834
<none>		2.0820	-163.805	
- X6	1	0.0968	2.1788	-163.351
+ X7	1	0.0224	2.0596	-162.389
+ X4	1	0.0164	2.0656	-162.232
- X1	1	0.6235	2.7055	-151.660
- X8	1	0.9745	3.0565	-145.072
- X2	1	2.8268	4.9088	-119.490
- X3	1	5.0791	7.1611	-99.097

Exemplo:

Step: AIC=-163.83
y ~ X3 + X2 + X8 + X1 + X6 + X5

	Df	Sum of Sq	RSS	AIC
<none>			2.0052	-163.834
- X5	1	0.0768	2.0820	-163.805
- X6	1	0.0977	2.1029	-163.265
+ X7	1	0.0332	1.9720	-162.736
+ X4	1	0.0023	2.0029	-161.896
- X1	1	0.6282	2.6335	-151.117
- X8	1	0.9002	2.9055	-145.809
- X2	1	2.7626	4.7678	-119.064
- X3	1	5.0801	7.0853	-97.672

Call:
lm(formula = y ~ X3 + X2 + X8 + X1 + X6 + X5, data = Xy)

Coefficients:						
(Intercept)	X3	X2	X8	X1	X6	X5
4.05397	0.01512	0.01376	0.35090	0.07152	0.08732	-0.00345

Introdução

Verificar se um modelo candidato tem bom desempenho em dados independentes daqueles usados para ajuste.

- Coletar novos dados para verificar o modelo e seu poder preditivo.
- Deixar parte dos dados de fora do ajuste, para usar na validação.

Validação de Modelos

Validação Cruzada

Quando temos um grande número de observações, podemos dividir os dados em duas partes:

Com o subconjunto ajustamos o modelo.

Com o subconjunto verificamos o poder preditivo do modelo.

Calculamos o :

MSPR = \frac{\sum_{i=1}^{n^*} (Y_i - \hat{Y}_i)^2}{n}

em que Y_i é o valor da variável resposta da i -ésima observação do conjunto teste, \hat{Y}_i é o valor predito para a i -ésima observação do conjunto teste segundo o modelo usando o conjunto treinamento e n^* é o total de observações no conjunto teste.

Exemplo - Modelo 1

```
dadosT <- read.table("./dados/CH09TA05.txt")
colnames(dadosT) <- c("X1", "X2", "X3", "X4", "X5", "X6", "X7", "X8", "Y", "lnY")
modelo1 <- lm(lnY ~ X1 + X2 + X3 + X8, data=dados)
yhat <- predict(modelo1, newdata=dadosT)
MSPR <- function(yhat, yobs) {
  mean((yobs - yhat)^2)
}
```

Variável	Estimativa	Erro-Padrão
Intercepto	3.8524186	0.1926952
X ₁	0.0733226	0.018973
X ₂	0.0141851	0.0017306
X ₃	0.0154527	0.0013956
X ₈	0.3529676	0.0771906

MSE é 0.044 e MSPR é 0.077

Exemplo

Temos 54 observações que não foram utilizadas na escolha do modelo para os dados sobre cirurgia. Este será o conjunto de dados .

Com os dados de , obtemos, usando $PRESS_p$ e BIC_p :

Modelo 1:

\ln(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_8 X_8 + \varepsilon

Usando C_p , temos o Modelo 2:

\ln(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_5 X_5 + \beta_8 X_8 + \varepsilon

Usando AIC_p e $R^2_{a,p}$, temos o Modelo 3:

\ln(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_5 X_5 + \beta_6 X_6 + \beta_8 X_8 + \varepsilon

Exemplo - Modelo 2

```
modelo2 <- lm(lnY ~ X1 + X2 + X3 + X5 + X8, data=dados)
yhat <- predict(modelo2, newdata=dadosT)
```

Variável	Estimativa	Erro-Padrão
Intercepto	4.0381206	0.2376904
X ₁	0.0736065	0.0188341
X ₂	0.0140523	0.0017208
X ₃	0.0154557	0.0013853
X ₅	-0.0034296	0.0026061
X ₈	0.3412188	0.0771389

MSE é 0.044 e MSPR é 0.08

Exemplo - Modelo 3

```
modelo3 <- lm(lnY ~ X1 + X2 + X3 + X5 + X6 + X8, data=dados)
yhat <- predict(modelo3, newdata=dadosT)
```

Variável	Estimativa	Erro-Padrão
Intercepto	4.0539742	0.2347935
X ₁	0.0715171	0.0186373
X ₂	0.0137555	0.0017094
X ₃	0.0151165	0.0013853
X ₅	-0.0034501	0.0025718
X ₆	0.0873166	0.0577017
X ₈	0.3509039	0.0763914

MSE é 0.043 e MSPR é 0.079

Leitura

- Applied Linear Statistical Models: Capítulo 9.
- Faraway - [Linear Models with R](#): Capítulo 10
- Draper & Smith - [Applied Regression Analysis](#): Capítulo 15.
- Tutorial: [Model Selection in R](#)
- [bestglm](#)

