

ME613 - Análise de Regressão

Parte 11

Samara F. Kiihl - IMECC - UNICAMP

Critérios para Seleção de Modelos

Introdução

Fases na construção de um modelo:

- · Coleta e preparação dos dados.
- · Redução do número de variáveis preditoras.
- · Refinamento e seleção de modelo.
- · Validação do modelo.

Introdução

Se tivermos p-1 variáveis preditoras, podemos construir 2^{p-1} modelos diferentes.

Mesmo se considerarmos todos esses modelos (computacionalmente intenso), precisaríamos de algum critério para selecionar entre eles.

Métodos para seleção de modelos/variáveis foram desenvolvidos para identificar um subgrupo de variáveis que são "boas" para o modelo, segundo algum critério.

Há vários critérios desenvolvidos na literatura. Neste curso, focaremos em seis.

R_p^2

Para o critério R_p^2 , a idéia é utilizar o coeficiente de determinação, R^2 para identificar subgrupos das variáveis preditoras que, quando incluídas no modelo, produzem um alto valor para R^2 .

 R_p^2 indica que temos p parâmetros no modelo, isto é, p-1 variáveis preditoras incluídas no modelo.

$$R_p^2 = 1 - \frac{SQE_p}{SQT}$$

O objetivo deste critério não é maximização: R_p^2 sempre irá aumentar conforme mais variáveis preditoras são incluídas no modelo. A idéia é comparar os diversos R_p^2 's e verificar se adicionar mais variáveis ainda traz um aumento.

Exemplo: Cirurgias

Y: tempo de sobrevivência

 X_1 : blood clotting score

*X*₂: índice de prognóstico

 X_3 : teste de função enzimática

*X*₄: teste de função do fígado

 X_5 : idade (anos)


 X_6 : gênero (0=masculino, 1=feminino)

 X_7 : uso de álcool (1 = moderado, 0 = nenhum ou severo)

 X_8 : uso de álcool (1 = severo, 0 = nenhum ou moderado)

Considerando X_1 , X_2 , X_3 e X_4 , temos $2^4 = 16$ modelos possíveis.

Variáveis no modelo	р	R_p^2	Variáveis no modelo	р	R_p^2
nenhuma	1	0	$X_2 X_3$	3	0.663
X_1	2	0.061	$X_2 X_4$	3	0.483
X_2	2	0.221	$X_3 X_4$	3	0.599
X_3	2	0.428	$X_1 X_2 X_3$	4	0.757
X_4	2	0.422	$X_1 X_2 X_4$	4	0.487
$X_1 X_2$	3	0.263	$X_1 X_3 X_4$	4	0.612
$X_1 X_3$	3	0.549	$X_2 X_3 X_4$	4	0.718
X_1 X_4	3	0.43	$X_1 X_2 X_3 X_4$	5	0.759




$$R_{a,p}^2$$

Como R_p^2 não leva em conta o número de parâmetros no modelo e sempre aumenta conforme temos mais variáveis incluídas, uma alternativa é usar:

$$R_{a,p}^2 = 1 - \left(\frac{n-1}{n-p}\right) \frac{SQE_p}{SQT} = 1 - \frac{QME_p}{SQT/(n-1)}$$

 $R_{a,p}^2$ aumenta se e somente se QME_p diminui.

Variáveis no modelo	р	$R_{a,p}^2$	Variáveis no modelo	р	$R_{a,p}^2$
nenhuma	1	0	$X_2 X_3$	3	0.65
X_1	2	0.043	$X_2 X_4$	3	0.463
X_2	2	0.206	$X_3 X_4$	3	0.584
X_3	2	0.417	$X_1 X_2 X_3$	4	0.743
X_4	2	0.41	$X_1 X_2 X_4$	4	0.456
$X_1 X_2$	3	0.234	$X_1 X_3 X_4$	4	0.589
$X_1 X_3$	3	0.531	$X_2 X_3 X_4$	4	0.701
$X_1 X_4$	3	0.408	$X_1 \ X_2 \ X_3 \ X_4$	5	0.74



Este critério avalia o erro quadrático médio dos n valores ajustados segundo um modelo a ser considerado.

Erro de cada valor ajustado é dado por:

$$\hat{Y}_i - \mu_i$$

em que μ_i é o valor verdadeiro da função resposta.

Temos o viés:

$$E(\hat{Y}_i) - \mu_i$$

E um componente aleatório de erro:

$$\hat{Y}_i - E(\hat{Y}_i)$$

$$(\hat{Y}_i - \mu_i)^2 = [(E(\hat{Y}_i) - \mu_i) + (\hat{Y}_i - E(\hat{Y}_i))]^2$$
$$E(\hat{Y}_i - \mu_i)^2 = [E(\hat{Y}_i) - \mu_i]^2 + Var(\hat{Y}_i)$$

Erro quadrático médio total:

$$\sum_{i=1}^{n} [E(\hat{Y}_i) - \mu_i]^2 + \sum_{i=1}^{n} Var(\hat{Y}_i)$$

Medida para o critério:

$$\Gamma_{p} = \frac{1}{\sigma^{2}} \left[\sum_{i=1}^{n} [E(\hat{Y}_{i}) - \mu_{i}]^{2} + \sum_{i=1}^{n} Var(\hat{Y}_{i}) \right]$$

(erro quadrático médio total dividido pela verdadeira variância do erro)

Estamos considerando incluir p-1 variáveis, mas assuma que o número ideal de variáveis a serem incluídas no modelo seja P-1>p-1.

Se assumirmos que o modelo incluindo as P-1 variáveis é correto, temos que $QME(X_1, ..., X_{P-1})$ é um estimador não viesado para σ^2 .

Estimador para Γ_p é dado por:

$$C_p = \frac{SQE_p}{QME(X_1, \dots, X_{P-1})} - (n-2p)$$

Se o modelo com p-1 variáveis é adequado, então $E\left[\frac{SQE_p}{(n-p)}\right]=\sigma^2$, de maneira que $E\left[\frac{SQE_p}{QME(X_1,...,X_{P-1})}\right]=n-p$.

Portanto, se o modelo com p-1 variáveis é aproximadamente adequado, esperamos que $C_p \approx p$.

Procuramos o menor C_p tal que $C_p \approx p$.


Modelo considerando as variáveis X_1 , X_2 , X_3 e X_4 (P-1=4)

Incluindo apenas X_4 (p=2):

$$C_p = \frac{SQE(X_4)}{QME(X_1, \dots, X_4)} - (n - 2p)$$

```
## Analysis of Variance Table
## Response: lnY
            Df Sum Sg Mean Sg F value Pr(>F)
## X4 1 5.3990 5.3990 37.894 1.092e-07 ***
## Residuals 52 7.4087 0.1425
## ---
## Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' ' 1
## Analysis of Variance Table
##
## Response: lnY
             Df Sum Sg Mean Sg F value Pr(>F)
       1 0.7763 0.7763 12.3337 0.0009661 ***
## X1
## X2
       1 2.5888 2.5888 41.1325 5.377e-08 ***
      1 6.3341 6.3341 100.6408 1.810e-13 ***
1 0.0246 0.0246 0.3905 0.5349320
## X3
           1 0.0246 0.0246
## X4
                                0.3905 0.5349320
## Residuals 49 3.0840 0.0629
## ---
## Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' ' 1
                C_p = \frac{SQE(X_4)}{OME(X_1, \dots, X_4)} - (n - 2p) = \frac{7.4087314}{0.062938} - (54 - 2 \times 2) = 67.7147725
```

```
library(leaps)
leaps<-regsubsets(lnY~X1+X2+X3+X4,data=dados,nbest=10)
plot(leaps,scale="Cp")</pre>
```



AIC e BIC

Procuramos modelos com valores pequenos de AIC, BIC.


AIC:

$$AIC_p = n \ln(SQE_p) - n \ln n + 2p$$

BIC:

$$BIC_p = n \ln(SQE_p) - n \ln n + \ln(n)p$$

plot(leaps,scale="bic")



$PRESS_{p}$

 $PRESS_p$ (): critério para medir quão adequado é o uso dos valores ajustados obtidos a partir de um modelo com menos variáveis para predizer os valores observados de Y.

 $SQE = \sum (Y_i - \hat{Y}_i)^2$ também serve para este propósito.

A diferença é que a medida PRESS é obtida após a exclusão da i-ésima observação e estimação do modelo com as n-1 observações restantes, e então usar este modelo para predizer o valor de Y para a i-ésima observação.

Notação: $\hat{Y}_{i(i)}$ indica o valor predito para a i-ésima observação quando esta foi excluída na obtenção do modelo.

$PRESS_{p}$

$$PRESS_p = \sum_{i=1}^{n} (Y_i - \hat{Y}_{i(i)})^2$$

Modelos com $PRESS_p$ pequenos são considerados bons candidatos (com erro de predição pequeno).

Não é preciso ajustar n-1 vezes o modelo para calcular o $PRESS_p$.

Seja
$$d_i = Y_i - \hat{Y}_{i(i)}$$
, reescrevemos: $d_i = \frac{e_i}{1 - h_{ii}}$

em que e_i é o resíduo para a i-ésima observação e h_{ii} é o i-ésimo elemento da diagonal de $\mathbf{H} = \mathbf{X}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}$, obtidos a partir do modelo de regressão com todas as observações incluídas.

```
library(qpcR)
modelo1 <- lm(lnY ~ 1,data=dados)</pre>
modelo2 <- lm(lnY ~ X1,data=dados)</pre>
modelo3 <- lm(lnY ~ X2,data=dados)</pre>
modelo4 <- lm(lnY ~ X3,data=dados)</pre>
modelo5 <- lm(lnY ~ X4,data=dados)</pre>
modelo6 <- lm(lnY ~ X1+X2,data=dados)</pre>
modelo7 <- lm(lnY ~ X1+X3,data=dados)</pre>
modelo8 <- lm(lnY ~ X1+X4,data=dados)</pre>
modelo9 <- lm(lnY ~ X2+X3,data=dados)</pre>
modelo10 <- lm(lnY ~ X2+X4,data=dados)</pre>
modelo11 <- lm(lnY ~ X3+X4,data=dados)</pre>
modelo12 <- lm(lnY ~ X1+X2+X3,data=dados)</pre>
modelo13 <- lm(lnY ~ X1+X2+X4,data=dados)</pre>
modelo14 <- lm(lnY ~ X1+X3+X4,data=dados)</pre>
modelo15 <- lm(lnY ~ X2+X3+X4,data=dados)</pre>
modelo16 <- lm(lnY ~ X1+X2+X3+X4,data=dados)</pre>
PRESS(modelo1, verbose=FALSE) $stat
## [1] 13.2956
```

Variáveis no modelo	р	$PRESS_p$	Variáveis no modelo	р	$PRESS_p$
nenhuma	1	13.296	$X_2 X_3$	3	5.065
X_1	2	13.512	$X_2 X_4$	3	7.476
X_2	2	10.744	$X_3 X_4$	3	6.121
X_3	2	8.327	$X_1 X_2 X_3$	4	3.914
X_4	2	8.025	$X_1 X_2 X_4$	4	7.903
$X_1 X_2$	3	11.062	$X_1 X_3 X_4$	4	6.207
$X_1 X_3$	3	6.988	$X_2 X_3 X_4$	4	4.597
$X_1 X_4$	3	8.472	$X_1 \ X_2 \ X_3 \ X_4$	5	4.069

Procedimentos Automáticos para Seleção de Modelos

"Best" Subsets Algorithms

Para o exemplo visto anteriormente, se considerarmos todas as variáveis, temos $2^8 = 256$ modelos possíveis.

Exemplo - Usando AIC_p

```
library(bestglm)
Xy = dados[,-9] # excluindo coluna do Y original, usamos ln(Y) como variável resposta
names(Xy) <- c(names(Xy)[1:8],"y")
modelos <- bestqlm(Xy,IC="AIC",TopModels = 2)</pre>
modelos$Subsets
      (Intercept)
##
                    X1
                          X2
                                Х3
                                      Χ4
                                           X5
                                                 X6
                                                             X8
## 0
            TRUE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## 1
            TRUE FALSE FALSE TRUE FALSE FALSE FALSE FALSE
            TRUE FALSE TRUE TRUE FALSE FALSE FALSE FALSE
## 2
## 3
            TRUE FALSE TRUE
                             TRUE FALSE FALSE FALSE
                       TRUE TRUE FALSE FALSE FALSE
## 4
            TRUE TRUE
                                                           TRUE
                        TRUE
                             TRUE FALSE FALSE
## 5
            TRUE
                 TRUE
                                              TRUE FALSE
                                                           TRUE
## 6*
            TRUE
                 TRUE
                        TRUE
                             TRUE FALSE
                                        TRUE
                                               TRUE FALSE
                                                           TRUE
                             TRUE FALSE
## 7
            TRUE
                 TRUE
                        TRUE
                                         TRUE
                                               TRUE
                                                     TRUE
                                                           TRUE
## 8
            TRUE TRUE TRUE
                             TRUE TRUE TRUE TRUE
                                                     TRUE
                                                          TRUE
     logLikelihood
                          AIC
##
          38.85126 -77.70252
## 0
## 1
          53.91343 -105.82686
          68.24165 -132.48329
## 2
## 3
          79.49246 -152.98493
          86.67568 -165.35135
## 4
## 5
          87.90259 -165.80517
          88.91714 -165.83429
## 6*
          89.36782 -164.73565
## 7
## 8
          89.38549 -162.77098
```

Exemplo - Usando AIC_p

```
melhor <- which(modelos$Subsets$AIC==min(modelos$Subsets$AIC))</pre>
numvar <- dim(Xy)[2]-1 # total de variáveis consideradas inicialmente
varincluidas <- modelos$Subsets[melhor,2:(numvar+1)] # variaveis escolhidas segundo criterio</pre>
varincluidas
        X1 X2 X3
                       X4 X5 X6
                                        X7 X8
## 6* TRUE TRUE TRUE FALSE TRUE TRUE FALSE TRUE
modeloescolhidoAIC <- lm(y \sim ., data=Xy[,c(which(varincluidas==TRUE),which(names(Xy)=="y"))])
summary(modeloescolhidoAIC)$coef
                   Estimate Std. Error t value
                                                      Pr(>|t|)
## (Intercept) 4.053974209 0.234793506 17.266126 5.572016e-22
## X1
                0.071517057 0.018637294 3.837309 3.701898e-04
                0.013755482 0.001709437 8.046792 2.169036e-10
## X2
## X3
               0.015116499 0.001385313 10.911972 1.777375e-14
## X5
               -0.003450094 0.002571776 -1.341522 1.861972e-01
               0.087316639 0.057701672 1.513243 1.369140e-01
## X6
                0.350903932 0.076391406 4.593500 3.276184e-05
## X8
```

Exemplo - Usando BIC_p

```
modelos <- bestglm(Xy,IC="BIC")
modelos$Subsets</pre>
```

```
(Intercept)
                                          X5
##
                    X1
                         X2
                               Х3
                                     X4
                                                X6
                                                      X7
                                                            X8
## 0
            TRUE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## 1
            TRUE FALSE FALSE TRUE FALSE FALSE FALSE FALSE
## 2
            TRUE FALSE
                       TRUE
                             TRUE FALSE FALSE FALSE FALSE
## 3
                             TRUE FALSE FALSE FALSE
            TRUE FALSE
                       TRUE
                            TRUE FALSE FALSE FALSE
## 4*
            TRUE TRUE
                       TRUE
                                                          TRUE
            TRUE
                 TRUE
                       TRUE
                                              TRUE FALSE
## 5
                             TRUE FALSE FALSE
                                                          TRUE
## 6
            TRUE
                 TRUE
                       TRUE
                             TRUE FALSE
                                        TRUE
                                              TRUE FALSE
                                                          TRUE
                             TRUE FALSE
                                        TRUE
## 7
            TRUE
                 TRUE
                       TRUE
                                              TRUE
                                                    TRUE
                                                          TRUE
## 8
            TRUE TRUE TRUE
                                              TRUE
                            TRUE TRUE TRUE
                                                    TRUE
                                                         TRUE
     logLikelihood
                         BIC
##
          38.85126 -77.70252
## 0
## 1
          53.91343 -103.83788
## 2
          68.24165 -128.50532
## 3
          79.49246 -147.01798
## 4*
          86.67568 -157.39542
          87.90259 -155.86025
## 5
## 6
          88.91714 -153.90039
## 7
          89.36782 -150.81276
## 8
          89.38549 -146.85911
```

Exemplo - Usando BIC_p

```
melhor <- which(modelos$Subsets$BIC==min(modelos$Subsets$BIC))</pre>
varincluidas <- modelos$Subsets[melhor,2:(numvar+1)] # variaveis escolhidas segundo criterio</pre>
varincluidas
        X1 X2 X3
##
                        X4
                              X5
                                          X7
                                               X8
## 4* TRUE TRUE TRUE FALSE FALSE FALSE TRUE
modeloescolhidoBIC <- lm(y \sim ., data=Xy[,c(which(varincluidas==TRUE),which(names(Xy)=="y"))])
summary(modeloescolhidoBIC)$coef
##
                 Estimate Std. Error t value
                                                    Pr(>|t|)
## (Intercept) 3.85241856 0.192695224 19.992289 3.279284e-25
               0.07332263 0.018973044 3.864569 3.273887e-04
## X1
## X2
              0.01418507 0.001730632 8.196469 9.581863e-11
## X3
              0.01545270 0.001395609 11.072371 6.145977e-15
              0.35296762 0.077190626 4.572675 3.290701e-05
## X8
```

Exemplo - Usando PRESS_p

```
modelos <- bestglm(Xy,IC="L00CV")
modelos$Subsets</pre>
```

```
(Intercept)
                                                X6
##
                    X1
                         X2
                               Х3
                                     X4
                                           X5
                                                      X7
                                                            X8
## 0
            TRUE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## 1
            TRUE FALSE FALSE TRUE FALSE FALSE FALSE FALSE
## 2
            TRUE FALSE
                       TRUE
                             TRUE FALSE FALSE FALSE FALSE
## 3
                             TRUE FALSE FALSE FALSE
            TRUE FALSE
                       TRUE
                            TRUE FALSE FALSE FALSE
## 4*
            TRUE TRUE
                       TRUE
                                                          TRUE
            TRUE
                 TRUE
                       TRUE
## 5
                             TRUE FALSE FALSE
                                              TRUE FALSE
                                                          TRUE
## 6
            TRUE
                 TRUE
                       TRUE
                             TRUE FALSE
                                        TRUE
                                              TRUE FALSE
                                                          TRUE
            TRUE
                             TRUE FALSE
                                        TRUE
## 7
                 TRUE
                       TRUE
                                              TRUE
                                                    TRUE
                                                          TRUE
## 8
            TRUE TRUE TRUE
                            TRUE TRUE TRUE
                                              TRUE
                                                    TRUE
                                                         TRUE
     logLikelihood
                        L00CV
##
          38.85126 0.24621473
## 0
## 1
          53.91343 0.15419845
## 2
          68.24165 0.09380257
## 3
          79.49246 0.06424821
## 4*
          86.67568 0.05069947
          87.90259 0.05153172
## 5
## 6
          88.91714 0.05133936
          89.36782 0.05201306
## 7
## 8
          89.38549 0.05428207
```

Exemplo - Usando PRESS_p

```
melhor <- which(modelos$Subsets$L00CV==min(modelos$Subsets$L00CV))</pre>
varincluidas <- modelos$Subsets[melhor,2:(numvar+1)] # variaveis escolhidas segundo criterio</pre>
varincluidas
        X1 X2 X3
##
                        X4
                              X5
                                          X7
                                               X8
## 4* TRUE TRUE TRUE FALSE FALSE FALSE TRUE
modeloescolhidoPRESS <- lm(y \sim ., data=Xy[,c(which(varincluidas==TRUE),which(names(Xy)=="y"))])
summary(modeloescolhidoPRESS)$coef
##
                 Estimate Std. Error t value
                                                    Pr(>|t|)
## (Intercept) 3.85241856 0.192695224 19.992289 3.279284e-25
               0.07332263 0.018973044 3.864569 3.273887e-04
## X1
## X2
              0.01418507 0.001730632 8.196469 9.581863e-11
## X3
              0.01545270 0.001395609 11.072371 6.145977e-15
              0.35296762 0.077190626 4.572675 3.290701e-05
## X8
```

Exemplo - C_p de Mallow, R_p^2 , $R_{a,p}^2$ e BIC_p

```
library(leaps)
modelos <- regsubsets(y ~ .,data=Xy,nbest=2)</pre>
resultados = data.frame(cbind("p"=rowSums(summary(modelos)$which),summary(modelos)$which,
                             "Cp"=round(summary(modelos)$cp,2),
                             "R2"=round(summary(modelos)$rsq.2).
                         "R2adi"=round(summary(modelos)$adjr2,2),"BIC"=round(summary(modelos)$bic,2)))
resultados
     p X.Intercept. X1 X2 X3 X4 X5 X6 X7 X8
                                                    R2 R2adi
                                                                BIC
## 1 2
                                         0 117.41 0.43
                                                       0.42 - 22.15
                                   0 0
## 2 2
                                         0 119.17 0.42
                                                        0.41 - 21.58
                                   0 0
## 3 3
                                   0 0 0 50.47 0.66
                                                       0.65 -46.81
                                0
## 4 3
                                         0
                                            69.13 0.60
                                                        0.58 - 37.44
## 5 4
                                        1 18.91 0.78
                                                        0.76 - 65.33
                                         0
                                            24.98 0.76
## 6 4
                                                        0.74 - 60.50
## 7 5
                                   0 0
                                        1
                                             5.75 0.83
                                                        0.82 -75.70
## 8 5
                                   0 0
                                        1 10.27 0.81 0.80 -71.01
## 9 6
                                0
                                   1 0 1
                                             5.54 0.84
                                                       0.82 -74.17
## 10 6
                                   0 0 1
                                             6.02 0.84 0.82 -73.63
## 11 7
                                             5.79 0.84
                                                        0.82 -72.21
## 12 7
                                            7.03 0.84 0.82 -70.76
## 13 8
                  1 1 1 1 0 1 1 1 1
                                             7.03 0.85 0.82 -69.12
                                            7.74 0.84 0.82 -68.28
## 14 8
## 15 9
                  1 1 1 1 1 1 1 1 1 9.00 0.85 0.82 -65.17
```

Método

- · Método menos intensivo computacionalmente.
- · Ao final, obtém-se apenas 1 modelo candidato.

• , ,

Início considerando P-1 variáveis.

1- Ajuste uma regressão linear simples com cada uma das P-1 variáveis. Para cada regressão, calcule a estatística t^* para testar se o coeficiente angular é 0.

$$t_k^* = \frac{\hat{\beta}_k}{\sqrt{\widehat{Var}(\hat{\beta}_k)}}$$

- 2- Considere a variável cujo $|t^*|$ é o maior. Inclua esta variável caso $|t^*|$ esteja acima de algum valor prédeterminado.
- 3 Se alguma variável é incluída, por exemplo, X_7 ajustam-se regressões com pares de variáveis, sendo que sempre uma delas é X_7 . Calcula-se t^* para a nova variável incluída e repita o passo 2 para decidir qual a segunda variável a ser incluída no modelo.
- 4 Repita até considerar todas as variáveis.

- 1. Ajuste uma regressão linear múltipla com todas as P-1 variáveis.
- 2. Teste iterativamente se uma das variáveis pode ser eliminada.

```
completo = lm(y\sim ., data=Xy)
vazio = lm(y\sim 1, data=Xy)
step(vazio, scope=list(upper=completo, lower=vazio), direction='forward', trace=TRUE)
Start: AIC=-75.7
y ~ 1
       Df Sum of Sq
                       RSS
                                 AIC
+ X3
            5.4762 7.3316 -103.827
+ X4
           5.3990 7.4087 -103.262
+ X2
            2.8285 9.9792 -87.178
+ X8
            1.7798 11.0279 -81.782
+ X1
            0.7763 12.0315 -77.079
+ X6
            0.6897 12.1180 -76.692
                    12.8077 -75.703
<none>
+ X5
            0.2691 12.5386 -74.849
+ X7
            0.2052 12.6025 -74.575
       1
```

```
Step: AIC=-103.83
y ~ X3
       Df Sum of Sq RSS
                              AIC
+ X2
           3.01908 4.3125 -130.48
+ X4
           2.20187 5.1297 -121.11
+ X1
           1.55061 5.7810 -114.66
+ X8
            1.13756 6.1940 -110.93
                    7.3316 -103.83
<none>
+ X6
            0.25854 7.0730 -103.77
+ X5
            0.23877 7.0928 -103.61
+ X7
            0.06498 7.2666 -102.31
```

```
Step: AIC=-130.48
y \sim X3 + X2
       Df Sum of Sq RSS
                               AIC
+ X8
           1.46961 2.8429 -150.99
+ X1
           1.20395 3.1085 -146.16
+ X4
           0.69836 3.6141 -138.02
+ X7
           0.22632 4.0862 -131.39
+ X5
            0.16461 4.1479 -130.59
                    4.3125 -130.48
<none>
+ X6
            0.08245 4.2300 -129.53
```

```
Step: AIC=-150.98
y \sim X3 + X2 + X8
       Df Sum of Sq RSS
                              AIC
+ X1
           0.66408 2.1788 -163.35
+ X4
           0.46630 2.3766 -158.66
+ X6
           0.13741 2.7055 -151.66
<none>
                   2.8429 -150.99
+ X5
       1 0.07081 2.7721 -150.35
+ X7
           0.02464 2.8182 -149.46
```

```
Step: AIC=-163.81

y ~ X3 + X2 + X8 + X1 + X6

Df Sum of Sq RSS AIC

+ X5 1 0.076782 2.0052 -163.83

<none> 2.0820 -163.81

+ X7 1 0.022387 2.0596 -162.39

+ X4 1 0.016399 2.0656 -162.23
```

```
Step: AIC=-163.83
y \sim X3 + X2 + X8 + X1 + X6 + X5
       Df Sum of Sq
                       RSS
                               AIC
                    2.0052 -163.83
<none>
       1 0.033193 1.9720 -162.74
+ X7
+ X4
     1 0.002284 2.0029 -161.90
Call:
lm(formula = y \sim X3 + X2 + X8 + X1 + X6 + X5, data = Xy)
Coefficients:
(Intercept)
                                   X2
                                                X8
                                                             X1
                                                                          X6
                                                                                        X5
                      X3
    4.05397
                                                        0.07152
                                                                     0.08732
                 0.01512
                              0.01376
                                           0.35090
                                                                                  -0.00345
```

```
completo = lm(y \sim ., data=Xy)
vazio = lm(y\sim 1, data=Xy)
step(completo, scope=list(upper=completo, lower=vazio), direction='backward', trace=TRUE)
Start: AIC=-160.77
v \sim X1 + X2 + X3 + X4 + X5 + X6 + X7 + X8
       Df Sum of Sq
                    RSS
                              AIC
- X4
           0.00129 1.9720 -162.74
- X7
     1 0.03220 2.0029 -161.90
- X5
           0.07354 \ 2.0443 \ -160.79
                    1.9707 -160.77
<none>
- X6
       1 0.08415 2.0549 -160.51
- X1
      1 0.31809 2.2888 -154.69
- X8
      1 0.84573 2.8165 -143.49
- X2
      1 2.09045 4.0612 -123.72
- X3
           2.99085 4.9616 -112.91
```

```
Step: AIC=-162.74
y \sim X1 + X2 + X3 + X5 + X6 + X7 + X8
      Df Sum of Sq RSS
                               AIC
- X7
            0.0332 2.0052 -163.834
                   1.9720 -162.736
<none>
- X5
            0.0876 2.0596 -162.389
- X6
            0.0971 2.0691 -162.141
- X1
           0.6267 2.5988 -149.833
- X8
           0.8446 2.8166 -145.486
- X2
           2.6731 4.6451 -118.471
- X3
            5.0986 7.0706 -95.784
```

```
Step: AIC=-163.83
y \sim X1 + X2 + X3 + X5 + X6 + X8
      Df Sum of Sq RSS
                              AIC
                  2.0052 -163.834
<none>
- X5
           0.0768 2.0820 -163.805
- X6
          0.0977 2.1029 -163.265
- X1
     1 0.6282 2.6335 -151.117
- X8
     1 0.9002 2.9055 -145.809
- X2
          2.7626 4.7678 -119.064
- X3
           5.0801 7.0853 -97.672
```

```
Call:
lm(formula = y \sim X1 + X2 + X3 + X5 + X6 + X8, data = Xy)
Coefficients:
(Intercept)
                      X1
                                   X2
                                                X3
                                                              X5
                                                                           X6
                                                                                        X8
    4.05397
                 0.07152
                              0.01376
                                           0.01512
                                                        -0.00345
                                                                      0.08732
                                                                                   0.35090
```

```
completo = lm(y\sim ., data=Xy)
vazio = lm(y\sim 1, data=Xy)
step(vazio, scope=list(upper=completo, lower=vazio), direction='both', trace=TRUE)
Start: AIC=-75.7
v ~ 1
       Df Sum of Sq
                       RSS
                                 AIC
+ X3
            5.4762 7.3316 -103.827
+ X4
            5.3990 7.4087 -103.262
+ X2
            2.8285 9.9792 -87.178
+ X8
            1.7798 11.0279 -81.782
+ X1
            0.7763 12.0315 -77.079
+ X6
            0.6897 12.1180 -76.692
                    12.8077 -75.703
<none>
+ X5
            0.2691 12.5386 -74.849
+ X7
            0.2052 12.6025 -74.575
```

```
Step: AIC=-103.83
y ~ X3
      Df Sum of Sq
                       RSS
                                AIC
+ X2
            3.0191 4.3125 -130.483
+ X4
            2.2019
                    5.1297 -121.113
+ X1
            1.5506
                    5.7810 -114.658
+ X8
            1.1376
                    6.1940 -110.932
<none>
                    7.3316 -103.827
+ X6
            0.2585
                    7.0730 - 103.765
+ X5
            0.2388
                    7.0928 -103.615
+ X7
            0.0650 7.2666 -102.308
- X3
            5.4762 12.8077 -75.703
```

```
Step: AIC=-130.48
y \sim X3 + X2
       Df Sum of Sq RSS
                               AIC
+ X8
            1.4696 2.8429 -150.985
+ X1
            1.2040 3.1085 -146.161
+ X4
            0.6984 3.6141 -138.023
+ X7
            0.2263 4.0862 -131.394
+ X5
            0.1646 4.1479 -130.585
                    4.3125 -130.483
<none>
+ X6
            0.0824 4.2300 -129.526
- X2
           3.0191 7.3316 -103.827
- X3
            5.6667 9.9792 -87.178
```

```
Step: AIC=-150.98
y \sim X3 + X2 + X8
       Df Sum of Sq RSS
                               AIC
+ X1
            0.6641 2.1788 -163.351
+ X4
           0.4663 2.3766 -158.659
+ X6
            0.1374 2.7055 -151.660
                    2.8429 -150.985
<none>
+ X5
            0.0708 2.7721 -150.347
+ X7
            0.0246 2.8182 -149.455
- X8
            1.4696 4.3125 -130.483
- X2
            3.3511 6.1940 -110.932
- X3
            4.9456 7.7885 -98.562
```

```
Step: AIC=-163.35
y \sim X3 + X2 + X8 + X1
       Df Sum of Sq RSS
                               AIC
+ X6
            0.0968 2.0820 -163.805
                    2.1788 -163.351
<none>
+ X5
            0.0759 2.1029 -163.265
+ X4
            0.0417 2.1371 -162.395
+ X7
            0.0229 2.1559 -161.923
- X1
            0.6641 2.8429 -150.985
- X8
            0.9297 3.1085 -146.161
- X2
           2.9873 5.1661 -118.731
- X3
            5.4513 7.6301 -97.671
```

```
Step: AIC=-163.81
y \sim X3 + X2 + X8 + X1 + X6
       Df Sum of Sq
                    RSS
                                AIC
+ X5
             0.0768 2.0052 -163.834
                    2.0820 -163.805
<none>
- X6
            0.0968 2.1788 -163.351
+ X7
            0.0224 2.0596 -162.389
+ X4
            0.0164 2.0656 -162.232
- X1
            0.6235 2.7055 -151.660
- X8
            0.9745 3.0565 -145.072
- X2
            2.8268 4.9088 -119.490
- X3
            5.0791 7.1611 -99.097
```

```
Step: AIC=-163.83
y \sim X3 + X2 + X8 + X1 + X6 + X5
      Df Sum of Sq
                      RSS
                               AIC
                   2.0052 -163.834
<none>
- X5
            0.0768 2.0820 -163.805
- X6
            0.0977 2.1029 -163.265
+ X7
       1 0.0332 1.9720 -162.736
+ X4
       1 0.0023 2.0029 -161.896
- X1
       1 0.6282 2.6335 -151.117
- X8
       1 0.9002 2.9055 -145.809
- X2
       1 2.7626 4.7678 -119.064
- X3
       1 5.0801 7.0853 -97.672
Call:
lm(formula = y \sim X3 + X2 + X8 + X1 + X6 + X5, data = Xy)
Coefficients:
(Intercept)
                     Х3
                                 X2
                                              X8
                                                           X1
                                                                        X6
                                                                                    X5
   4.05397
                0.01512
                             0.01376
                                          0.35090
                                                      0.07152
                                                                   0.08732
                                                                              -0.00345
```

Validação de Modelos

Introdução

Verificar se um modelo candidato tem bom desempenho em dados independentes daqueles usados para ajuste.

- · Coletar novos dados para verificar o modelo e seu poder preditivo.
- · Deixar parte dos dados de fora do ajuste, para usar na validação.

Validação Cruzada

Quando temos um grande número de observações, podemos dividir os dados em duas partes: e .

Com o subconjunto ajustamos o modelo.

Com o subconjunto verificamos o poder preditivo do modelo.

Calculamos o

$$MSPR = \frac{\sum_{i=1}^{n^*} (Y_i - \hat{Y}_i)^2}{n^*}$$

em que Y_i é o valor da variável resposta da i-ésima observação do conjunto teste, \hat{Y}_i é o valor predito para a i-ésima observação do conjunto teste segundo o modelo usando o conjunto treinamento e n^* é o total de observações no conjunto teste.

Temos 54 observações que não foram utilizadas na escolha do modelo para os dados sobre cirurgia. Este será o conjunto de dados .

Com os dados de

, obtemos, usando $PRESS_p$ e BIC_p :

Modelo 1:

$$ln(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_8 X_8 + \varepsilon$$

Usando C_p , temos o Modelo 2:

$$ln(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_5 X_5 + \beta_8 X_8 + \varepsilon$$

Usando AIC_p e $R_{a,p}^2$, temos o Modelo 3:

$$ln(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_5 X_5 + \beta_6 X_6 + \beta_8 X_8 + \varepsilon$$

Exemplo - Modelo 1

```
dadosT <- read.table("./dados/CH09TA05.txt")</pre>
colnames(dadosT) <- c("X1","X2","X3","X4","X5","X6","X7","X8","Y","lnY")</pre>
modelo1 \leftarrow lm(lnY \sim X1 + X2 + X3 + X8, data=dados)
yhat <- predict(modelo1,newdata=dadosT)</pre>
MSPR <- function(yhat,yobs){</pre>
  mean((yobs-yhat)^2)
 Variável
                                          Estimativa
                                                                                   Erro-Padrão
 Intercepto
                                          3.8524186
                                                                                   0.1926952
 X_1
                                          0.0733226
                                                                                   0.018973
                                          0.0141851
                                                                                   0.0017306
 X_2
 X_3
                                          0.0154527
                                                                                   0.0013956
 X_8
                                          0.3529676
                                                                                   0.0771906
```

MSE é 0.044 e *MSPR* é 0.077

Exemplo - Modelo 2

modelo2 <- $lm(lnY \sim X1 + X2 + X3 + X5 + X8, data=dados)$ yhat <- predict(modelo2, newdata=dadosT)

Variável	Estimativa	Erro-Padrão
Intercepto	4.0381206	0.2376904
X_1	0.0736065	0.0188341
X_2	0.0140523	0.0017208
X_3	0.0154557	0.0013853
X_5	-0.0034296	0.0026061
X_8	0.3412188	0.0771389

MSE é 0.044 e MSPR é 0.08

Exemplo - Modelo 3

modelo3 <- $lm(lnY \sim X1 + X2 + X3 + X5 + X6 + X8, data=dados)$ yhat <- predict(modelo3, newdata=dadosT)

Variável	Estimativa	Erro-Padrão
Intercepto	4.0539742	0.2347935
X_1	0.0715171	0.0186373
X_2	0.0137555	0.0017094
X_3	0.0151165	0.0013853
X_5	-0.0034501	0.0025718
X_6	0.0873166	0.0577017
X_8	0.3509039	0.0763914

MSE é 0.043 e *MSPR* é 0.079

Leitura

- · Applied Linear Statistical Models: Capítulo 9.
- Faraway Linear Models with R: Capítulo 10
- Draper & Smith Applied Regression Analysis: Capítulo 15.
- · Tutorial: Model Selection in R
- · bestglm

