



# ME613 - Análise de Regressão

Parte 13

Benilton S Carvalho - 1S2020

# Regressão Não-Linear

# Introdução

$$Y_i = f(\mathbf{X}_i, \boldsymbol{\beta}) + \varepsilon_i$$

em que  $\mathbf{X}_i$  é o vetor dos valores observados das variáveis preditoras para o  $i$ -ésimo caso:

$$\mathbf{X}_{i \times p} = \begin{pmatrix} 1 \\ X_{i,1} \\ \vdots \\ X_{i,p-1} \end{pmatrix}$$

e  $\boldsymbol{\beta}$  o vetor de coeficientes.

No caso de regressão linear, temos que:

$$f(\mathbf{X}_i, \boldsymbol{\beta}) = \mathbf{X}_i^T \boldsymbol{\beta}$$

# Introdução

Regressão não-linear:

$$Y_i = f(\mathbf{X}_i, \boldsymbol{\gamma}) + \varepsilon_i$$

Exemplos:


$$Y_i = \gamma_0 \exp(\gamma_1 X_i) + \varepsilon_i$$

$$Y_i = \gamma_0 + \gamma_1 \exp(\gamma_2 X_i) + \varepsilon_i$$

$$Y_i = \frac{\gamma_0}{1 + \gamma_1 \exp(\gamma_2 X_i)} + \varepsilon$$


# Exemplo

$$E(Y) = 100 - 50 \exp(-2X)$$




# Exemplo

$$E(Y) = \frac{10}{1 + 20 \exp(-2X)}$$



# Exemplo

$$E(Y) = 100 - 50 \exp(-2X)$$



# Regressão Não-linear

No caso linear, o número de parâmetros é igual ao número de elementos em  $\mathbf{X}_i$ , no caso não-linear não temos, necessariamente, esta relação.

$$Y_i = f(\mathbf{X}_i, \boldsymbol{\gamma}) + \varepsilon_i$$

$$\mathbf{X}_{i \times q} = \begin{pmatrix} X_{i,1} \\ \vdots \\ X_{i,q} \end{pmatrix}$$

$$\boldsymbol{\gamma}_{p \times 1} = \begin{pmatrix} \gamma_0 \\ \gamma_1 \\ \vdots \\ \gamma_{p-1} \end{pmatrix}$$



# Exemplo - Pacientes

$X$ : dias de hospitalização


$Y$ : prognóstico

##		Y	X
##	1	54	2
##	2	50	5
##	3	45	7
##	4	37	10
##	5	35	14
##	6	25	19
##	7	20	26
##	8	16	31
##	9	18	34
##	10	13	38
##	11	8	45
##	12	11	52
##	13	8	53
##	14	4	60
##	15	6	65

Modelo proposto:  $Y_i = \gamma_0 \exp(\gamma_1 X_i) + \varepsilon_i$ .

# Exemplo - Pacientes

$$\hat{Y}_i = 58.6065 \exp(-0.03959X_i) + \varepsilon_i.$$



# Mínimos Quadrados

Relembrando, no modelo linear simples:

$$S = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2$$

No modelo não-linear:

$$S = \sum_{i=1}^n [Y_i - f(\mathbf{X}_i, \boldsymbol{\gamma})]^2$$

Queremos minimizar  $S$  com relação a  $\gamma_0, \gamma_1, \dots, \gamma_{p-1}$ .

# Mínimos Quadrados

$$\frac{\partial S}{\partial \gamma_k} = \sum_{i=1}^n -2[Y_i - f(\mathbf{X}_i, \boldsymbol{\gamma})] \left[ \frac{\partial f(\mathbf{X}_i, \boldsymbol{\gamma})}{\partial \gamma_k} \right]$$

Igualando as  $p$  derivadas parciais a zero e substituindo os parâmetros  $\gamma_k$  pelas estimativas  $g_k$ , temos as  $p$  equações normais:

$$\sum_{i=1}^n Y_i \left[ \frac{\partial f(\mathbf{X}_i, \boldsymbol{\gamma})}{\partial \gamma_k} \right]_{\boldsymbol{\gamma}=\mathbf{g}} - \sum_{i=1}^n f(\mathbf{X}_i, \mathbf{g}) \left[ \frac{\partial f(\mathbf{X}_i, \boldsymbol{\gamma})}{\partial \gamma_k} \right]_{\boldsymbol{\gamma}=\mathbf{g}} = 0 \quad k = 0, 1, \dots, p-1$$

em que  $\mathbf{g}$  é o vetor de estimativas por mínimos quadrados:

$$\mathbf{g}_{p \times 1} = \begin{pmatrix} g_0 \\ g_1 \\ \vdots \\ g_{p-1} \end{pmatrix}$$

# Exemplo - Pacientes

$$Y_i = \gamma_0 \exp(\gamma_1 X_i) + \varepsilon_i$$

$$f(\mathbf{X}_i, \gamma) = \gamma_0 \exp(\gamma_1 X_i)$$

$$\frac{\partial f(\mathbf{X}_i, \gamma)}{\partial \gamma_0} = \exp(\gamma_1 X_i)$$

$$\frac{\partial f(\mathbf{X}_i, \gamma)}{\partial \gamma_1} = \gamma_0 X_i \exp(\gamma_1 X_i)$$

# Exemplo - Pacientes

Equações normais:

$$\sum_{i=1}^n Y_i \left[ \frac{\partial f(\mathbf{X}_i, \boldsymbol{\gamma})}{\partial \gamma_k} \right]_{\boldsymbol{\gamma}=\mathbf{g}} - \sum_{i=1}^n f(\mathbf{X}_i, \mathbf{g}) \left[ \frac{\partial f(\mathbf{X}_i, \boldsymbol{\gamma})}{\partial \gamma_k} \right]_{\boldsymbol{\gamma}=\mathbf{g}} = 0 \quad k = 0, 1$$

Temos:

$$\sum_{i=1}^n Y_i \exp(g_1 X_i) - \sum_{i=1}^n g_0 \exp(g_1 X_i) \exp(g_1 X_i) = 0$$

$$\sum_{i=1}^n Y_i g_0 X_i \exp(g_1 X_i) - \sum_{i=1}^n g_0 \exp(g_1 X_i) g_0 X_i \exp(g_1 X_i) = 0$$

# Exemplo - Pacientes

Simplificando:

$$\sum_{i=1}^n Y_i \exp(g_1 X_i) - g_0 \sum_{i=1}^n \exp(2g_1 X_i) = 0$$

$$\sum_{i=1}^n Y_i X_i \exp(g_1 X_i) - g_0 \sum_{i=1}^n X_i \exp(2g_1 X_i) = 0$$

As equações normais não são lineares com relação a  $g_0$  e  $g_1$  e não possuem solução com forma fechada. Métodos numéricos devem ser empregados para obter a solução.

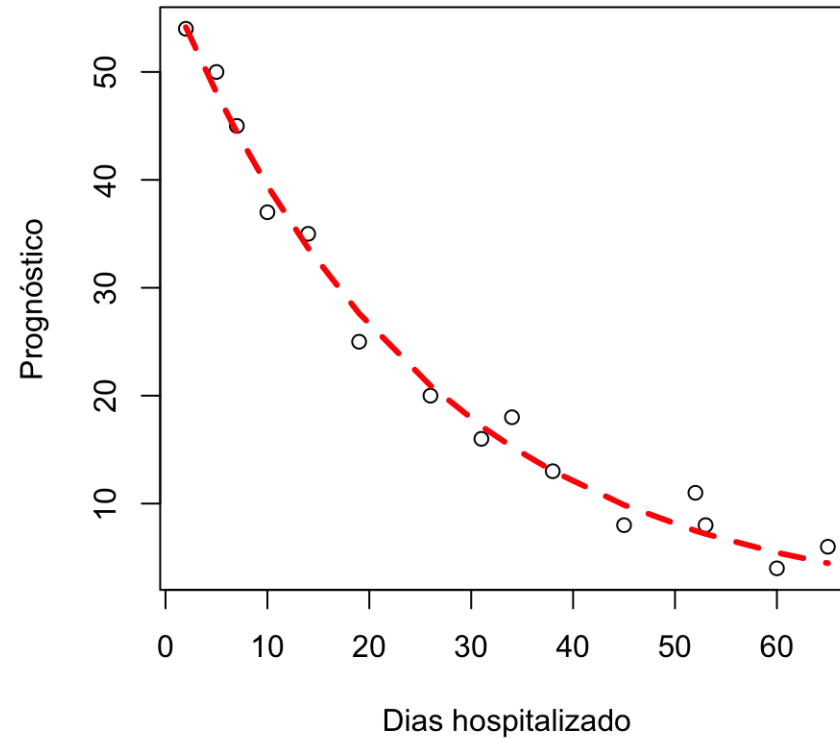
# Exemplo - Pacientes

```
m <- nls(Y~gamma0*exp(gamma1*X),data=dados,start=list(gamma0=56.6646,gamma1=-0.03797))  
summary(m)$coef
```

##		Estimate	Std. Error	t value	Pr(> t )
##	gamma0	58.6065313	1.472159424	39.80991	5.699631e-15
##	gamma1	-0.0395864	0.001711292	-23.13246	6.013445e-12



# Exemplo - Pacientes



# Exemplo - Pacientes

Para obter os valores iniciais, note que podemos linearizar:

$$\log_e \gamma_0 [\exp(\gamma_1 X_i)] = \log_e \gamma_0 + \gamma_1 X_1$$

$$Y_i^* = \beta_0 + \beta_1 X_i + \varepsilon_i$$

em que  $Y_i^* = \log_e Y_i$ ,  $\beta_0 = \log_e \gamma_0$  e  $\beta_1 = \gamma_1$ .

```
modeloL <- lm(log(Y) ~ X,data=dados)
summary(modeloL)$coef
```

```
##              Estimate Std. Error  t value    Pr(>|t|)
## (Intercept)  4.03715887 0.084103145  48.00247 5.081672e-16
## X           -0.03797418 0.002284209 -16.62465 3.857871e-10
```

$$g_0^{(0)} = \exp(\hat{\beta}_0) = 56.665 \text{ e } g_1^{(0)} = \hat{\beta}_1 = -0.038.$$

# Agradecimento

- Slides criados por Samara F Kiihl / IMECC / UNICAMP

# Leitura

- Applied Linear Statistical Models: Seções 13.1-13.4.
- Draper & Smith - [Applied Regression Analysis](#): Capítulo 24.
- [Nonlinear Regression and Nonlinear Least Squares in R](#)